Lab 03: Verbos principales para manipulacion de datos

Actividad

Fase 1: Aprendizaje independiente en su grupo original (3 minutos)

- Nos dividimos en grupos de 5 personas.
- Cada grupo tiene un experto para los distinctos aspectos:

    1. caracteristicas de los datos tidy y la manipulación con pipelines
    2. operaciones a nivel de **tabela**
    3. operaciones a nivel de **fila**
    4. operaciones a nivel de **columna**
    5. uniendo datos

- El experto, estudia el material sobre su enfoque específico.

Fase 2: Aprendizaje colaborativo en grupos de expertos (3 minutos)

- Los expertos de cada enfoque se reúnen en grupos para compartir sus conocimientos.
- Aclaran dudas entre expertos, toman notas y se preparan para enseñar a su grupo original.
- El experto prepara un reporte breve de:

    1. ¿Qué hace esta operación?
    2. ¿Qué cambia: las filas, las columnas, los valores, o el número de observaciones?
    3. Dé un ejemplo ecológico de cuándo la usaría. De la experiencia reciente con el analisis de datos en su grupo, mencione un caso concreto.

Fase 3: Enseñanza en el grupo original (5 minutos)

- Cada experto regresa a su grupo original y enseña a los demás miembros del grupo sobre su área específica.
- Se discuten y resuelven dudas sobre las temas presentados por los expertos.

Fase 4: Reflexión y cierre (5 minutos)

- Se comparten conclusiones y se resuelven dudas finales con toda la clase.
- Cada grupo original (no grupo de expertos) tiene que resolver la situación de la siguiente página (caja roja).

! Situación (Fase 4)

Cada grupo original (no grupo de expertos) tiene que resolver la siguiente situación:
Tenemos una tabla llamada `muestras` con la abundancia (conteo) de macroinvertebrados de 4 sitios, medida en varias fechas; cada muestra cubre un área fija de 0.25 m².

sitio	fecha	conteo

Tenemos una segunda tabla llamada `sitios`, con un solo valor de temperatura y oxígeno por cada uno de los 4 sitios (estos valores no varían por fecha).

sitio	temperatura	oxígeno

Queremos, a partir de la tabla `muestras`:

- quedarnos solamente con las muestras de septiembre (columna `fecha`);
- agregar una columna de densidad (individuos/m²), dividiendo el conteo entre el área de la muestra;
- calcular la densidad promedio de septiembre por sitio;
- ordenar los sitios de mayor a menor densidad promedio;
- agregar, para cada sitio, la temperatura y oxígeno desde la tabla sitios.

¿Qué operaciones necesitamos y en qué orden? ¿Con qué columna(s) se debe hacer la unión (join) entre las dos tablas?

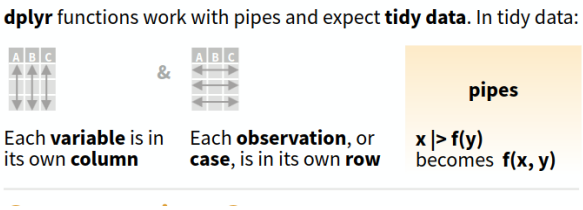
Material

En lo que sigue se presentan las principales funciones de manipulación de datos en R utilizando el enfoque tidy data. Todos los imagenes provienen del `dplyr` cheatsheet disponible en el siguiente enlace: dplyr cheatsheet.

Tidy data (Datos ordenados) (experto 1)

Datos tidy:

- Cada columna representa una variable.
- Cada fila representa una observación.



Pipelines, el operador `|>` o `%>%`:

- Facilitan la manipulación de datos tidy.
- Toman la salida de una operación y la pasan como entrada a la siguiente operación
- Esto permite encadenar múltiples transformaciones de manera clara y concisa.

```
datos |> filter(variable > valor) |> summarise(promedio = mean(variable))
```

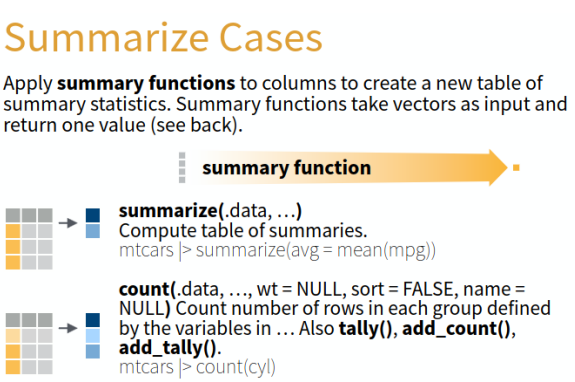
Operaciones a nivel de tabela (experto 2)

Resumenes

`summarise()`:

- Aplica una funcion para generar nueva tabela con resúmenes.
- Permite obtener estadísticas descriptivas.
- Se utiliza comúnmente junto con `group_by()` para obtener resúmenes por grupo.

```
datos |> summarise(promedio = mean(variable))
```

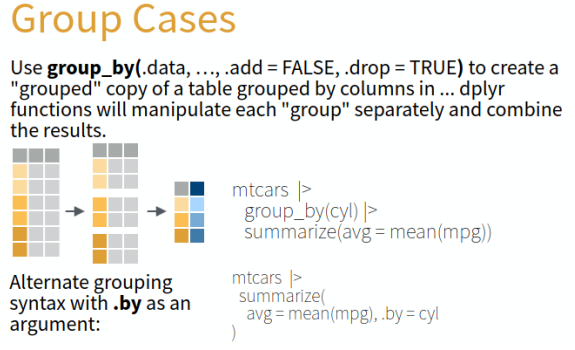


Agrupamiento

`group_by()`:

- Agrupa los datos según una o más variables.
- Crea version modificada de los datos con el agrupamiento aplicado.
- Todos operaciones posteriores se aplican dentro de cada grupo.
- Se utiliza comúnmente junto con `summarise()` para obtener resúmenes por grupo.

```
datos |> group_by(variable_categorica)
```



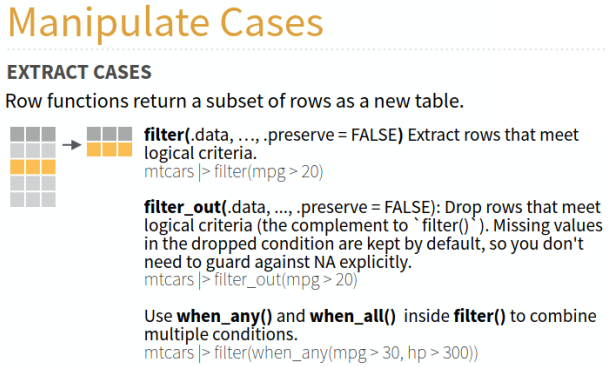
Operaciones a nivel de fila (experto 3)

Filtrado (selección de filas)

`filter()`:

- Selecciona filas que cumplen con una condición específica.
- Permite filtrar los datos según valores de las columnas.
- Se utiliza comúnmente para enfocarse en subconjuntos relevantes de los datos.

```
datos |> filter(variable > valor)
```

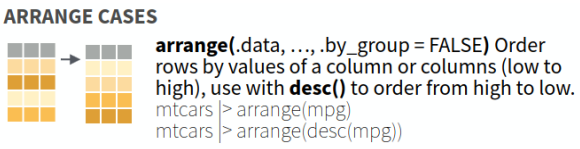


Ordenamiento de filas

`arrange()`:

- Ordena las filas de un data frame según una o más columnas.
- Permite especificar el orden ascendente o descendente.
- Facilita la visualización y el análisis de los datos en un orden específico.

```
datos |> arrange(variable)
```



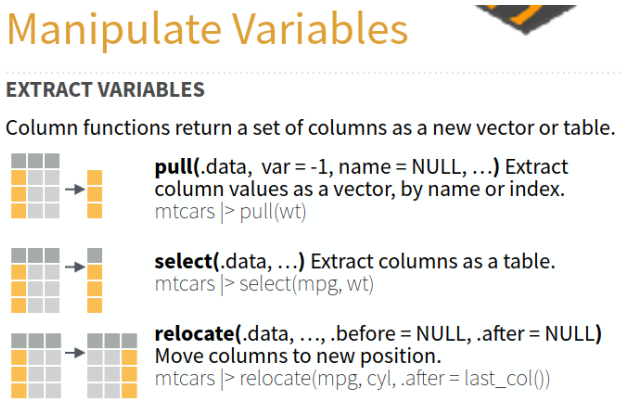
Operaciones a nivel de columna (experto 4)

Selección de columnas

`select()`:

- Permite elegir un subconjunto de columnas de un data frame.
- Facilita trabajar solo con las columnas relevantes.
- Se puede usar para reordenar columnas o renombrarlas.

```
datos |> select(columna1, columna2)
```

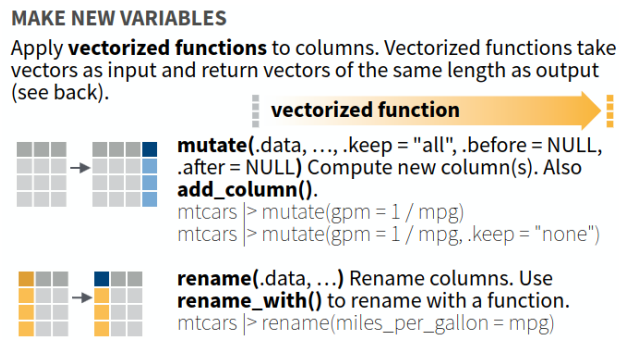


Creando nuevas columnas

`mutate()`:

- Crea nuevas columnas o modifica las existentes.
- Permite realizar cálculos basados en otras columnas.
- Se utiliza comúnmente para agregar información derivada a los datos.

```
datos |> mutate(nueva_columna = variable1 + variable2)
```



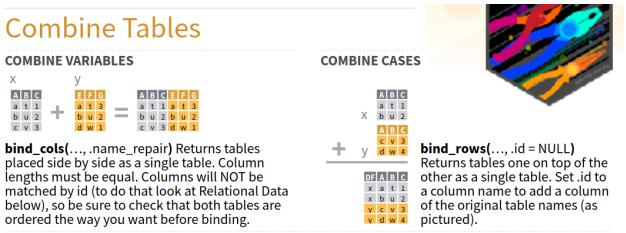
Uniendo datos (experto 5)

Uniendo datos sin claves

`bind_rows()`:

- Permite combinar varias tablas con las mismas columnas.

```
bind_rows(tabla1, tabla2)
```

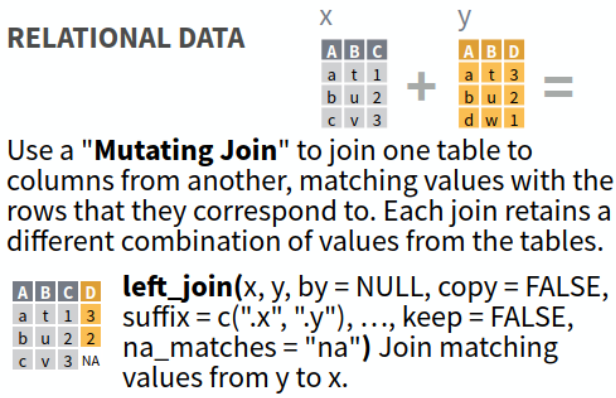


Uniendo datos con claves

`left_join()`:

- Permite combinar dos tablas según una clave común, conservando todas las filas de la tabla izquierda.
- Se utiliza comúnmente para agregar información adicional a un conjunto de datos existente.
- No conserva las filas de la tabla derecha que no tienen coincidencias en la tabla izquierda.

```
left_join(tabla1, tabla2, by = "clave")
```



> Hay otros tipos de uniones con claves, como `right_join()`, `inner_join()` y `full_join()`, que permiten combinar tablas de diferentes maneras según las necesidades del análisis.